

ANÁLISIS PREDICTIVO DE LA GESTIÓN DE LA AYUDA HUMANITARIA Y EL IMPACTO DE DESASTRES A NIVEL GLOBAL

I. INTRODUCCIÓN

Este proyecto explora distintos aspectos clave de la gestión de desastres y emergencias a nivel global utilizando técnicas de Machine Learning. En particular, se aborda la predicción de la eficiencia de la respuesta y el tiempo de recuperación, para comprender qué factores influyen en una respuesta más eficaz y rápida, y la identificación de zonas y tipos de desastre con altos impactos económicos y humanos. A través de modelos predictivos, el proyecto busca contribuir a mejorar la toma de decisiones en contextos humanitarios y de gestión de crisis.

Los **objetivos** de este proyecto son:

1. Predecir la eficiencia de respuesta: *¿Qué factores hacen que una respuesta a emergencias sea más eficiente?*
2. Predecir el tiempo de recuperación: *¿Cuánto tardará un país en recuperarse de un desastre?*
3. Realizar una segmentación de eventos por perfil de riesgo y gestión de la respuesta. Es decir, *identificar grupos naturales de eventos con el fin de detectar perfiles diferenciados - como eventos de alto riesgo con respuesta lenta o desastres moderados bien gestionados - y analizar qué países y tipos de desastre los concentran.*

II. DATASET

El **dataset** seleccionado para este proyecto se titula “[Enhanced Disaster & Emergency Response Dataset](#)” - es una versión mejorada del “[Global Disaster & Emergency Response Dataset \(2018–2024\)](#)” - y ha sido obtenido de Kaggle. Este dataset ofrece simulaciones sintéticas de desastres naturales en todo el mundo junto con sus correspondientes respuestas humanitarias. Cada registro representa un evento similar a los que se dan en el mundo real y contiene detalles sobre la intensidad, el impacto humano, los daños económicos, las iniciativas de ayuda y la eficacia de la recuperación.

Los datos se han generado utilizando modelos probabilísticos y distribuciones aleatorias para garantizar una variabilidad realista. Abarca un periodo de 35 años (1990-2024) e incluye 49.972 registros únicos distribuidos en 24 países que cubren 12 tipos de desastres: inundaciones,

deslizamientos de tierra, marejadas ciclónicas, incendios forestales, erupciones volcánicas, ciclones, sequías, frío extremo, calor extremo, tsunamis, tornados y terremotos.

III. PREPROCESAMIENTO DE LOS DATOS

Es importante señalar las siguientes **limitaciones** del dataset antes de interpretar cualquier resultado del modelo:

- Los datos han sido generados mediante modelos probabilísticos, no recogidos de eventos reales. Esto implica que los patrones aprendidos por los modelos no reflejan necesariamente la realidad de la gestión de desastres. Las métricas de evaluación serán probablemente muy elevadas por esta razón, no como consecuencia del poder predictivo real del modelo.

Esta desconexión con la realidad se manifiesta en varios aspectos, por ejemplo:

- El valor máximo registrado en `economic_loss` es de aproximadamente 68 millones de euros por evento. Desastres reales de referencia, como el terremoto de Turquía-Siria (2023), causaron pérdidas estimadas superiores a 34.000 millones de euros, una diferencia de orden de magnitud de aproximadamente $\times 500$.
- La media de víctimas por terremoto es de apenas 35, frente a los 220.000 del terremoto de Haití (2010) o los 50.000 del de Turquía-Siria (2023).
- La distribución temporal, reflejada en el número de eventos, tiene una aceleración más pronunciada que la documentada en fuentes como EM-DAT, pasando de 3.215 en los años 90 a 19.445 en los 2010.
- El análisis exploratorio revela correlaciones extremas entre algunas features y los targets, lo que sugiere que los targets fueron generados directamente a partir de las features mediante fórmulas deterministas. Esto limita el valor interpretativo de los modelos.

En cuanto a la transformación de variables, se han tomado las siguientes decisiones:


- a. Eliminar la fila con el único valor nulo del dataset, en la columna `economic_loss`.
- b. Limpiar las columnas `economic_loss` y `aid_amount`, eliminando el símbolo de moneda (€) y los separadores de miles (,), y pasándolas a float.
- c. Eliminar una fila sin datos en `recovery_days` y pasarla a float.

IV. ANÁLISIS EXPLORATORIO DE LOS DATOS (EDA)


Ninguna de las variables sigue una distribución normal. La gran mayoría tiene los datos muy concentrados en la izquierda con cola hacia la derecha. Además, excepto “year” y “response_score”, todas las variables tienen muchos outliers, indicando eventos con un alto número de personas muertas, graves pérdidas económicas, muchas horas de respuesta, cantidades altas de ayuda humanitaria y un número elevado de días de recuperación.

Estas asimetrías y outliers serán tenidos en cuenta durante el feature engineering, ya que algunos de los modelos predictivos son altamente sensibles a estas características en la distribución de los datos.

Histogramas con Skewness



Boxplots





Al graficar el mapa de calor de correlaciones, se observa que uno de los target principales (response_score) está directamente correlacionado con response_hours. Es decir, cuanto más tiempo tarda la respuesta ante la emergencia, peor es la calificación de la respuesta. Esta alta correlación negativa supone un problema para la predicción con algunos modelos, tales como la regresión lineal.


Heatmap de Correlaciones



Asimismo, las pérdidas económicas (economic_loss) y la ayuda de emergencia (aid_amount) destinadas a una catástrofe también están fuertemente correlacionadas. Esto debe ser tenido en cuenta al desarrollar las predicciones.




En los siguientes boxplot, se puede ver la relación de cada tipo de desastre y de cada país con el target “response_score”. Del tipo de desastre, se infiere que no tiene apenas efecto en la eficiencia de respuesta. Todos tienen medianas entre 70 y 85, aunque Extreme Cold y Tornado parecen tener medianas ligeramente más altas.



En cuanto al país, se aprecia una división en tres grupos:

- Países que responden bien (score > 85): EE UU, Japón, Alemania, Irlanda, Italia, Nueva Zelanda, Francia, España y Sudáfrica.
- Países que dependen del tipo de desastre (60-85): Turquía, Australia, Indonesia, Canadá, Grecia, Filipinas, México, India, Perú, Chile y China.
- Países que responden mal (score < 60): Nigeria, Brasil, Congo y Bangladesh.


Además, los outliers demuestran que incluso los países mejor preparados tienen eventos puntuales de muy mala gestión.



Asimismo, los siguientes boxplot grafican la relación de cada tipo de desastre y de cada país con el target “recovery_days”. En base al tipo de desastre, se aprecia que hay mucha varianza entre tipo de desastre. Por un lado, las temperaturas extremas y los ciclones son los más rápidos en recuperar, con medianas bajas y poca dispersión; es decir, pasada la emergencia/ola, la recuperación es inmediata. Por otro lado, hay varios tipos de eventos que, pese a haber tenido casos concretos de lenta recuperación, tienen una mediana alrededor de los 100-150 días: inundaciones, deslizamientos


de tierra, terremotos... Son, además, los tipos de desastre más numerosos en el dataset. Por último, cabe destacar los dos casos más extremos:

- Las erupciones volcánicas tienen los outliers más altos, llegando a 1750 días (unos 5 años). Esto sugiere que la mayoría de erupciones se gestionan razonablemente, pero cuando fallan, lo hacen de forma catastrófica y prolongada.
- El Tsunami tiene la mediana más alta (alrededor de 250 días). Es el tipo de desastre que más tarda en recuperarse de forma consistente, no sólo en casos extremos.



En cuanto al país, sí se ve una división en tres grupos bastante nítida, que parece coincidir aproximadamente con el nivel de desarrollo económico de cada país:

- Recuperación lenta (mediana > 300 días): Congo, Nigeria - con outliers extremos que llegan a 1.700 días.
- Recuperación media (100–300 días): Perú, Sudáfrica, Indonesia, Grecia, India, Brasil, Filipinas, Bangladesh, Turquía y Chile.
- Recuperación rápida (mediana < 100 días): España, China, México, Italia, Irlanda, Francia, Australia, Canadá, Nueva Zelanda, EE UU, Alemania, Japón.



Continuando el análisis por país, en los siguientes gráficos se puede observar los días de recuperación y la calificación de respuesta que cada uno ha tenido en función del tipo de desastre sufrido.


El caso más complejo es el Congo con erupciones volcánicas (1.057 días), seguido por Nigeria con tornados (807), Nigeria con deslizamientos de tierra (759) y Congo con ciclones (637). En el otro extremo, Japón es consistentemente verde en casi todos los tipos (18-20 días), igual que Alemania y EEUU, como nos indicaba el boxplot. Es decir, el país domina la señal de `recovery_days` más que el tipo de desastre.


No obstante, en cuanto al índice de respuesta se infiere que, aunque los países con mejores y peores calificaciones coinciden con los menores y mayores días de recuperación, sí hay algo de variación por tipo de desastre dentro del mismo país. Por ejemplo, Bangladesh responde muy mal a sequías, Nigeria a deslizamientos de tierra y Brasil a incendios, pero algo mejor a otros.

Por último, el próximo gráfico analiza la viabilidad de hacer una segmentación de eventos por perfil de riesgo y gestión de la respuesta mediante

PCA. Las cuatro variables seleccionadas - víctimas, pérdidas económicas, horas de respuesta y días de recuperación - explican conjuntamente el 71% de la varianza total y se distinguen tres zonas diferenciadas: una masa central densa que agrupa la mayoría de eventos, un brazo que se extiende hacia valores altos de PC1, y un grupo reducido pero claramente aislado en la zona inferior izquierda, cuya combinación de valores lo separa notablemente del resto del dataset.

La coloración por tipo de desastre y por país muestra que ninguna de estas categorías explica por sí sola la posición de los eventos en el espacio: los colores aparecen completamente mezclados en todas las zonas, lo que indica que eventos de distinto tipo y distinto país pueden tener perfiles de impacto y respuesta muy similares.





V. FEATURE ENGINEERING

En primer lugar, se han aplicado transformaciones logarítmicas a las cinco variables con mayor asimetría: `casualties`, `economic_loss`, `aid_amount`, `recovery_days` y `response_hours`. Estas variables presentaban distribuciones fuertemente asimétricas hacia la derecha, lo que perjudicaba el rendimiento de modelos sensibles a la escala como la regresión lineal o KMeans.

En segundo lugar, se ha aplicado One-Hot Encoding a las dos variables categóricas: `country` (24 categorías) y `disaster_type` (12 categorías), generando 36 columnas binarias adicionales. El dataframe resultante cuenta con 49 columnas en total.

VI. MODELADO

Dado que el proyecto aborda tres objetivos distintos, se han definido tres conjuntos de variables independientes, modelos y métricas que se ajustan a cada predicción concreta.

Para el objetivo 1 (predecir `response_score`), se excluyen `response_hours` y `response_hours_log` por data leakage directo y se incluye `recovery_days_log` como feature bajo la asunción de que la evaluación de la eficiencia de respuesta se da una vez se sabe los días de recuperación. Los modelos a utilizar son supervisados e incluyen regresión lineal, regularización (Lasso, Ridge, ElasticNet), RandomForestRegressor (y RandomizedSearchCV), GradientBoosting (y RandomizedSearchCV) y XGBoost. Por último, las métricas a valorar son R^2 , MAE y RMSE.

Además, una vez realizado el análisis de importancia de variables, se vio que `casualties_log` y `severity_index` conjuntamente explicaban el 84% de la varianza del modelo, lo que sugería que `response_score` pudo haber sido generado a partir de ellas. En consecuencia, se entrenó una versión adicional (Objetivo 1.2) excluyendo `severity_index` para valorar su impacto.

Para el objetivo 2 (predecir `recovery_days_log`), se excluye `response_score` por leakage temporal (siguiendo el razonamiento anterior, usarla equivaldría a mirar al futuro). Se utilizan los mismos modelos y las mismas métricas que en el objetivo 1.

Para el objetivo 3 (clustering), se utilizan las cuatro variables que definen el perfil de impacto y gestión: `casualties_log`, `economic_loss_log`, `response_hours_log` y `recovery_days_log`. Se excluye `aid_amount_log` por su alta correlación con `economic_loss_log` (0,87), y las variables categóricas se reservan para la interpretación posterior de los clusters, no para su construcción. En este caso, se analizan los modelos no supervisados KMeans, DBScan, HDBScan y UMAP, y la métrica Silhouette Score.

Para los objetivos supervisados se ha realizado una división 80/20, resultando en 39.976 registros de entrenamiento y 9.994 de test. El objetivo 3 no requiere split al ser no supervisado. Además, se ha realizado una estandarización mediante StandardScaler, uno por cada objetivo.

Una vez entrenados los modelos, las tres mejores métricas obtenidas son:

❖ Objetivo 1

Modelo	R^2	RMSE	MAE
<i>XGBoost</i>	0.9923	2.4454	0.9766
<i>GBM</i>	0.9920	2.4957	1.1359
<i>RandomForest</i>	0.9903	2.7486	1.0850

Los mejores parámetros son los de XGBoost. Además, los R^2 tan altos (> 0.99) confirman lo que se sospechaba: `response_score` fue generado a partir de las features mediante una fórmula determinista, por lo que las métricas no reflejan poder predictivo real sino que el modelo está aprendiendo esa fórmula.

❖ Objetivo 1.2

Modelo	R^2	RMSE	MAE
<i>XGBoost</i>	0.8515	10.7964	6.9606
<i>RandomForest</i>	0.8467	10.9691	6.8103
<i>GBM</i>	0.8411	11.1659	7.3213

Al eliminar `severity_index`, el R^2 de XGBoost cae de 0.992 a 0.852, y el RMSE sube de 2.4 a 10.8 puntos. Esto confirma el leakage: `severity_index` era una de las features con las que se calculó `response_score`. Asimismo, parece que hay un poco más de overfit en estos casos. No obstante, XGBoost sigue siendo el más equilibrado.

En cuanto al RMSE, 10 puntos en una escala de 0 a 100 es aceptable para los datos del dataset, pero es un valor alto en la realidad.

❖ Objetivo 2

Modelo	R^2	RMSE	MAE
<i>XGBoost</i>	0.786978	84.257597	42.382921
<i>GBM</i>	0.785663	84.182923	42.530276
<i>RandomForest</i>	0.780763	89.024764	43.514417

Los mejores parámetros, una vez más, los ofrece XGBoost. Por otra parte, un RMSE de 84 días es mucho, porque significa que el modelo se equivoca en media casi 3 meses al predecir cuánto tarda un país en recuperarse. En este sentido, hay dos lecturas posibles:


- La optimista: predecir `recovery_days` es inherentemente difícil porque depende de factores que no están en el dataset (tales como gobernanza, infraestructura, ayuda internacional concreta...), y un R^2 de 0.79 con variables tan generales no está mal.
- La pesimista: el dataset es sintético y, si `recovery_days` se generó con algo de ruido aleatorio grande, el modelo nunca podrá capturarlo del todo.

❖ Objetivo 3

Aunque no hay un elbow muy marcado, el mejor Silhouette Score corresponde a $k=2$ (0.2770) y los valores para $k=3$ (0.2155) a $k=6$ son cercanos y muy similares entre sí. En consecuencia, se probaron $k=2$ y $k=3$ para comparar su interpretabilidad y se seleccionó $k=3$ porque devolvía tres grupos con perfiles diferenciados y mayor riqueza interpretativa.

Las 4 variables de clustering se interpretan mediante PCA (71% de varianza explicada) donde:


- PC1 (45% varianza) carga principalmente en casualties (+0,665) y response_hours (+0,572); es decir, es el eje de impacto humano y gestión deficiente.
- PC2 (26% varianza) tiene carga positiva en economic_loss (+0,807) y negativa en response_hours (-0,553). Es el eje de contraste económico vs. operacional.



Al graficar los PCA, se observa mucho solapamiento entre los clusters, especialmente en el centro, lo que indica que los bordes entre perfiles son difusos, coherente con la naturaleza sintética del dataset.

Respecto a la distribución por tipo de desastre, en el siguiente gráfico se observa que los clusters son bastante proporcionales, lo que

reafirma que el tipo de desastre no es un predictor potente por sí solo. En cambio, la distribución por países sí muestra diferencias más visibles, observadas en el proceso de EDA.



Se han probado otras opciones de clustering con DBScan, HDBScan y UMAP, pero tanto por falta de conocimientos acerca del modelo, como por la interpretabilidad que se pierde, se ha optado por utilizar KMeans y dejar esta alternativa como futuros pasos del proyecto.

VII. RESULTADOS FINALES Y CONCLUSIÓN

El pipeline final incluye un modelo independiente por cada objetivos: XGBoost entrenado con severity_index para el objetivo 1, XGBoost sin severity_index para el objetivo 1.2, XGBoost para el objetivo 3 y un KMeans con k=3 para el objetivo 3.

Pese a que el dataset es sintético y estos modelos no son directamente aplicables a casos reales, este trabajo de Machine Learning ofrece posibilidades de predicción que ayudan en la gestión de respuesta de desastres naturales:

1. Por un lado, un análisis en clusters puede ayudar a identificar eventos de alto riesgo con recuperación lenta y anticipar las pérdidas económicas y los países que los concentran, orientando la planificación y asignación de ayuda humanitaria.
2. Asimismo, la previsión de días de recuperación puede apoyar la planificación logística y de recursos a medio plazo tras un desastre, dependiendo del tipo de desastre y el país donde sucede.
3. Por último, predecir el índice de respuesta puede proporcionar información sobre los factores asociados a una respuesta ágil y efectiva para detectar brechas de capacidad de respuesta en países vulnerables con puntuaciones sistemáticamente bajas.

VIII. FUTUROS PASOS

Este proyecto demuestra el potencial del Machine Learning en gestión humanitaria, pero está limitado por el uso de datos sintéticos. En consecuencia, sería interesante aplicar predicciones similares con datasets como EM-DAT, OCHA o el Banco Mundial, para que los modelos tengan valor predictivo real. Además, podría ser interesante incluir variables contextuales externas, como el Índice de Desarrollo Humano (IDH), el PIB per cápita o variables relacionadas con gobernanza e infraestructura.

Del mismo modo, aparte de continuar explorando las posibilidades de HDBScan y UMAP para clustering, se podría realizar un análisis temporal de frecuencia e intensidad de los desastres mediante modelos de series temporales como ARIMA, especialmente en el contexto del cambio climático.