





Desastres Naturales

Machine Learning



Bootcamp Data Science

Chiara López Palomino



Desastres Naturales

Objetivos

1. Predecir la **eficiencia de respuesta**:

¿Qué factores hacen que una respuesta a emergencias sea más ágil y eficiente?

2. Predecir el **tiempo de recuperación**: *¿Cuánto tardará un país en recuperarse de un desastre?*


→ Planificación logística y de recursos.

3. Realizar una **segmentación de eventos por perfil de riesgo y gestión de la respuesta**.

Identificar grupos naturales de eventos con el fin de detectar perfiles diferenciados

- como eventos de alto riesgo con respuesta lenta o desastres moderados bien gestionados -
y analizar qué países y tipos de desastre los concentran.

→ Asignación de ayuda humanitaria.



Desastres Naturales

Dataset

“Enhanced Disaster & Emergency Response Dataset” (Kaggle)

Dataset sintético de desastres naturales y respuesta humanitaria global (1990–2024).
Incluye ~50.000 registros de 24 países y 12 tipos de desastres, con variables sobre impacto humano, daños económicos, ayuda y recuperación.


Los datos fueron generados utilizando **modelos probabilísticos y distribuciones aleatorias** para garantizar una variabilidad realista.



Desastres Naturales

Limitaciones del dataset

- Como los datos son sintéticos, los patrones aprendidos por los modelos **no reflejan necesariamente la realidad de la gestión de desastres.**
- El EDA revela correlaciones extremas entre algunas features y los targets, sugiriendo que **los targets fueron generados directamente a partir de las features** mediante fórmulas deterministas.



Desastres Naturales

Response score por país

Se aprecia una división en tres grupos:


- Países que responden bien (score > 85): EE UU, Japón, Alemania, Irlanda, Italia, Nueva Zelanda, Francia, España y Sudáfrica.
- Países que dependen del tipo de desastre (60-85): Turquía, Australia, Indonesia, Canada, Grecia, Filipinas, México, India, Perú, Chile y China.
- Países que responden mal (score < 60): Nigeria, Brasil, Congo y Bangladesh.



**Outliers: ¡incluso los países mejor preparados tienen eventos puntuales de muy mala gestión!*

Desastres Naturales

Response score por desastre



No tiene apenas efecto en la eficiencia de respuesta (medianas similares).






Desastres Naturales

Response score
(por país y tipo de desastre)



Desastres Naturales

Response score
(por país y tipo de desastre)




División en tres grupos que **parece coincidir aproximadamente con el nivel de desarrollo económico** de cada país:

- Recuperación lenta (mediana > 300 días): Congo, Nigeria - con outliers extremos que llegan a 1.700 días.
- Recuperación media (100–300 días): Perú, Sudáfrica, Indonesia, Grecia, India, Brasil, Filipinas, Bangladesh, Turquía y Chile.
- Recuperación rápida (mediana < 100 días): España, China, México, Italia, Irlanda, Francia, Australia, Canadá, Nueva Zelanda, EE UU, Alemania, Japón.

Desastres Naturales

Recovery days por país

Recovery_days por tipo de desastre




Hay **mucha varianza** entre tipo de desastre.

- *Extreme Cold, Extreme Heat y Cyclone*: los más rápidos; pasada la emergencia/ola, la recuperación es inmediata.
- Eventos que tienen casos de lenta recuperación, pero mediana alrededor de los 100-150 días (más numerosos en el dataset).
- *Volcanic Eruption*: los outliers más altos, llegando a 1750 días. La mayoría de erupciones se gestionan razonablemente, pero si fallan es de forma catastrófica y prolongada.
- *Tsunami*: la mediana más alta (250 días). Es el tipo de desastre que más tarda en recuperarse.




Desastres Naturales


Recovery days por desastre



Desastres Naturales

Recovery days
(por país y tipo de desastre)





Desastres Naturales

Feature Engineering

Transformaciones logarítmicas para variables con distribuciones fuertemente asimétricas (modelos muy sensibles).

One-Hot Encoding a las dos variables categóricas: country (24 categorías) y disaster_type (12 categorías).




Desastres Naturales

Selección de variables

✦ ✦ **Objetivo 1** (*response_score*): excluir response hours por data leakage directo e incluir *recovery_days_log* como feature bajo la asunción de que la evaluación de la eficiencia de respuesta se da una vez se sabe los días de recuperación.

Objetivo 2 (*recovery_days*): excluir response score por leakage temporal (siguiendo el razonamiento anterior, usarla equivaldría a mirar al futuro).

Objetivo 3 (*clustering*): utilizar las variables que definen el perfil de impacto y gestión (casualties, economic_loss, response_hours y recovery_days). ✦ ✦



Desastres Naturales

Selección de modelos y métricas



Objetivos 1 y 2:

Modelos supervisados: regresión lineal, regularización (Lasso, Ridge, ElasticNet), RandomForestRegressor (+RandomizedSearchCV), GradientBoosting (+RandomizedSearchCV), XGBoost

Objetivo 3:

Modelos no supervisados: KMeans, DBScan, HDBScan, UMAP

Métricas: R2, MAE, RMSE, Silhouette Score



- 0.99: target creado mediante features (alto feature importance de severity_index)
- RMSE 10 (score): aceptable por el dataset, pero es mucho
- RMSE 84 días (3 meses): demasiado. O faltan factores externos o es por el dataset sintético


Objetivo	Modelo	R2	RMSE
1 (response_score)	XGBoost	0.9923	2.4454
1.2 (response_score sin severity index)	XGBoost	0.8515	10.7964
2 (recovery_days)	XGBoost	0.786978	84.257597

Desastres Naturales

Resultados (II)

Objetivo 3: $k=3 \rightarrow$ Silhouette Score 0.2155

- Cluster 0: **Impacto moderado** (mediana: 44 víctimas, 550k€ pérdida, 18h respuesta, 81 días recuperación)
- Cluster 1: **Alto impacto humano / Mala gestión** (40 víctimas, 800k€, 19h, 668 días - PC1 alto, concentrado en Congo, Nigeria, Indonesia)
- Cluster 2: **Alto daño económico / Buena gestión** (7 víctimas, 160k€, 8h, 54 días - PC2 alto, países más desarrollados)



Mucho solapamiento entre los clusters, especialmente en el centro; los bordes entre perfiles son difusos.



Desastres Naturales

Resultados (III)

$k=3 \rightarrow$ Silhouette Score 0.2155

- Cluster 0: **Impacto moderado** (mediana: 44 víctimas, 550k€ pérdida, 18h respuesta, 81 días recuperación)
- Cluster 1: **Alto impacto / Recuperación muy lenta** (40 víctimas, 800k€, 19h, 668 días - PC1 alto, concentrado en Congo, Nigeria, Indonesia)
- Cluster 2: **Respuesta eficiente** (7 víctimas, 160k€, 8h, 54 días - PC2 alto, países desarrollados)

(Variedad... el tipo de desastre no es un predictor potente por sí solo)



Desastres Naturales

¡A PREDECIR!





Desastres Naturales

Futuros pasos



- Utilizar **datasets como EM-DAT**, OCHA o el Banco Mundial, para que los modelos tengan valor predictivo real.
- Incluir **variables contextuales externas**, como el IDH, el PIB per cápita o variables relacionadas con gobernanza e infraestructura.
- Continuar explorando las posibilidades de **HDBScan y UMAP para clustering**.
- Realizar un **análisis temporal de frecuencia e intensidad** de los desastres (ej. ARIMA), especialmente en el contexto del cambio climático.



Eskerrik asko!
Q&A?